Nama : Priya Riz'Abbad Wijaya
Institusi : Universitas Jenderal Soedirman

A. Pendahuluan

Kanker kolorektal (*Colorectal Cancer*, CRC) menempati peringkat ketiga sebagai keganasan paling umum secara global dan penyebab kematian akibat kanker tertinggi kedua di dunia. Keterbatasan biomarker CRC menyebabkan sebagian besar kasus teridentifikasi pada stadium lanjut, sehingga diagnosis dini, penentuan prognosis, dan keberhasilan terapi menjadi terbatas. Oleh karena itu, penelitian ini bertujuan untuk mengidentifikasi gen inti (*core genes*, CGs) yang berperan dalam patogenesis CRC dan berpotensi sebagai biomarker untuk diagnosis dini, prognosis, serta pengembangan terapi.

B. Metode

1. Instalasi Perangkat Lunak

a. R 4.5.2

Bahasa pemrograman R versi 4.5.2 diinstal melalui situs resmi Comprehensive R Archive Network (CRAN) (https://cran.r-project.org/) dengan memilih sistem operasi komputer yang sesuai, dalam hal ini menggunakan Windows, dengan meng-klik teks "*Download R for Windows*" dan memilih "*install R for the first time*" lalu "*Download R-4.5.2 for Windows*". Proses instalasi perangkat lunak menggunakan pengaturan *default*.

b. RStudio

Perangkat lunak Rstudio versi 2026.01.1+403 diinstal melalui situs resmi Posit (https://posit.co/download/rstudio-desktop/) dengan meng-klik "*Download RStudio Desktop for windows*". Proses instalasi perangkat lunak menggunakan pengaturan *default*.

2. Analisis DEGs

Analisis DEGs dilakukan menggunakan dataset Microarray GSE106582 dengan platform GPL10558 (Illumina HumanHT-12 V4.0) yang didapatkan melalui database GEO (https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE106582) yang berisi 194 sampel, yaitu 77 sampel jaringan tumor/CRC dan 117 sampel jaringan normal.

Script R yang digunakan adalah sebagai berikut:

```
#Modul: Analisis Ekspresi Gen Penyebab Colorectal Cancer
#Dataset: GSE106582 (Tumor vs Adjacent)
#Platform: Microarray (Illumina HumanHT-12 V4.0 - GPL10558)
#Tujuan: Mengidentifikasi Differentially Expressed Genes (DEG)

#PART A. PENGANTAR KONSEP

#Analisis ekspresi gen bertujuan untuk membandingkan tingkat ekspresi gen
#Antara dua kondisi biologis (jaringan normal vs jaringan tumor)
#Pada modul ini kita menggunakan pendekatan statistik limma (Linear Models
#for Microarray Data), yang merupakan standar emas untuk data microarray.

#PART B. PERSIAPAN LINGKUNGAN KERJA (INSTALL & LOAD PACKAGE)

#Apa itu package?
#Package adalah kumpulan fungsi siap pakai di R
#Bioinformatika di R sangat bergantung pada package dari CRAN dan
Bioconductor

#1. Install BiocManager (manajer paket Bioconductor)
#IF adalah struktur logika : "jika kondisi terpenuhi, lakukan aksi"

if (!require("BiocManager", quietly = TRUE))  {
  install.packages("BiocManager")
}

# 2. Install paket Bioconductor (GEOquery & limma)
#GEOquery: mengambil data dari database GEO
#limma: analisis statistik ekspresi gen

BiocManager::install(c("GEOquery", "limma"), ask = FALSE, update = FALSE)

#illuminaHumanv4.db:  database  anotasi  khusus  untuk  chip  Illumina
(GSE106582)
BiocManager::install("illuminaHumanv4.db")

#3. Install paket CRAN untuk visualisasi dan manipulasi data
#phetmap: heatmap ekspresi gen
#ggplot2: grafik (volcano plot)
#dplyr: manipulasi tabel data
```

```
install.packages(c("pheatmap", "ggplot2", "dplyr"))

#umap: grafik (plot UMAP)
if (!requireNamespace("umap", quietly = TRUE)) {
  install.packages("umap")
}

#4. Memanggil library
#library() digunakan agar fungsi di dalam package bisa digunakan
library(GEOquery)
library(limma)
library(pheatmap)
library(ggplot2)
library(dplyr)
library(illuminaHumanv4.db)
library(AnnotationDbi)
library(umap)

#PART C. PENGAMBILAN DATA DARI GEO

#GEO (Gene Expression Omnibus) adalah database publik milik NCBI
#getGEO(): fungsi untuk mengunduh dataset berdasarkan ID GEO
#GSEMatrix = TRUE -> data diambil dalam format ExpressionSet
#AnnotGPL  = TRUE -> anotasi gen (Gene Symbol) ikut diunduh

gset <- getGEO("GSE106582", GSEMatrix = TRUE, AnnotGPL = TRUE)[[1]]

#ExpressionSet berisi:
# - exprs() : matriks ekspresi gen
# - pData() : metadata sampel
# - fData() : metadata fitur (probe / gen)

#PART D. PRE-PROCESSING DATA EKSPRESI

# exprs(): mengambil matriks ekspresi gen
# Baris  = probe/gen
# Kolom  = sampel
ex <- exprs(gset)

#Mengapa perlu log2 transformasi?
#Data microarray mentah memiliki rentang nilai sangat besar.
```

```
#Log2 digunakan untuk:
#1. Menstabilkan varians
#2. Mendekati asumsi model linear
#3. Memudahkan interpretasi log fold change

#quantile(): menghitung nilai kuantil (persentil)
#as.numeric(): mengubah hasil quantile (yang berupa named vector)
#menjadi vektor numerik biasa agar mudah dibandingkan
qx <- as.numeric(quantile(ex, c(0, 0.25, 0.5, 0.75, 0.99, 1), na.rm =
TRUE))

#LogTransform adalah variabel logika (TRUE / FALSE)
#Operator logika:
#>  : lebih besar dari
#|| : OR (atau)
#&& : AND (dan)
LogTransform <- (qx[5] > 100) || (qx[6] - qx[1] > 50 && qx[2] > 0)

#IF statement:
#Jika LogTransform = TRUE, maka lakukan log2
if (LogTransform) {
  # Nilai <= 0 tidak boleh di-log, maka diubah menjadi NA
  ex[ex <= 0] <- NA
  ex <- log2(ex)
}

#PART E. DEFINISI KELOMPOK SAMPEL

#pData(): metadata sampel
#Kita mengambil kolom 'characteristics_ch1.3' yang berisi informasi
kondisi jaringan sampel

group_info <- pData(gset)[["characteristics_ch1.3"]]

#make.names(): mengubah teks menjadi format valid untuk R
groups <- make.names(group_info)

#factor():
#Mengubah data kategorik menjadi faktor
#Faktor sangat penting untuk analisis statistik di R
gset$group <- factor(groups)
```

```
#levels(): melihat kategori unik dalam faktor
nama_grup <- levels(gset$group)
print(nama_grup)
#Harusnya muncul: “tissue..mucosa” dan “tissue..tumor”

#PART F. DESIGN MATRIX (KERANGKA STATISTIK)

#model.matrix():
#Membuat matriks desain untuk model linear
#~0 berarti TANPA intercept (best practice limma)
design <- model.matrix(~0 + gset$group)

#colnames(): memberi nama kolom agar mudah dibaca
colnames(design) <- levels(gset$group)

#Menentukan perbandingan biologis
Tumor <- "tissue..tumor"
Adjacent <- "tissue..mucosa"

contrast_formula <- paste(Tumor, "-", Adjacent)
print(paste("Kontras yang dianalisis:", contrast_formula))

#PART G. ANALISIS DIFFERENTIAL EXPRESSION (LIMMA)

#lmFit():
#Membangun model linear untuk setiap gen
fit <- lmFit(ex, design)

#makeContrasts(): mendefinisikan perbandingan antar grup
contrast_matrix <- makeContrasts(contrasts = contrast_formula, levels =
design)

#contrasts.fit(): menerapkan kontras ke model
fit2 <- contrasts.fit(fit, contrast_matrix)

#eBayes():
#Empirical Bayes untuk menstabilkan estimasi varians
fit2 <- eBayes(fit2)

#topTable():
```

```
#Mengambil hasil akhir DEG
#adjust = "fdr" -> koreksi multiple testing
#p.value = 0.05  -> gen signifikan
topTableResults <- topTable(
  fit2,
  adjust = "fdr",
  sort.by = "B",
  number = Inf,
  p.value = 0.05
)

head(topTableResults)

#PART H. ANOTASI NAMA GEN

#Penting:
#Pada data microarray Illumina, unit analisis awal adalah PROBE ID,
#bukan gen. Oleh karena itu, anotasi ulang diperlukan menggunakan
#database resmi Bioconductor (illuminaHumanv4.db).

#Mengambil ID probe dari hasil DEG
probe_ids <- rownames(topTableResults)

#Mapping probe -> gene symbol & gene name
#Gunakan database illuminaHumanv4
gene_annotation <- AnnotationDbi::select(
  illuminaHumanv4.db,
  keys = probe_ids,
  columns = c("SYMBOL", "GENENAME"),
  keytype = "PROBEID"
)

#Gabungkan dengan hasil limma
topTableResults$PROBEID <- rownames(topTableResults)

topTableResults <- merge(
  topTableResults,
  gene_annotation,
  by = "PROBEID",
  all.x = TRUE
)
```

```
#Cek hasil anotasi
head(topTableResults[, c("PROBEID", "SYMBOL", "GENENAME")])

#PART I.1 BOXPLOT DISTRIBUSI NILAI EKSPRESI

#Boxplot digunakan untuk:
#- Mengecek distribusi nilai ekspresi antar sampel
#- Melihat apakah ada batch effect
#- Mengevaluasi apakah normalisasi/log-transform sudah wajar

#Set warna berdasarkan grup
group_colors <- as.numeric(gset$group)

boxplot(
  ex,
  col = group_colors,
  las = 2,
  outline = FALSE,
  main = "Boxplot Distribusi Nilai Ekspresi per Sampel",
  ylab = "Expression Value (log2)"
)

legend(
  "topright",
  legend = levels(gset$group),
  fill = unique(group_colors),
  cex = 0.8
)

#PART I.2 DISTRIBUSI NILAI EKSPRESI (DENSITY PLOT)

#Density plot menunjukkan sebaran global nilai ekspresi gen
#Digunakan untuk:
#- Mengecek efek log-transform
#- Membandingkan distribusi antar grup

#Gabungkan ekspresi & grup ke data frame
expr_long <- data.frame(
  Expression = as.vector(ex),
  Group = rep(gset$group, each = nrow(ex))
```

```
)

ggplot(expr_long, aes(x = Expression, color = Group)) +
  geom_density(linewidth = 1) +
  theme_minimal() +
  labs(
    title = "Distribusi Nilai Ekspresi Gen",
    x = "Expression Value (log2)",
    y = "Density"
  )

#PART I.3 UMAP (VISUALISASI DIMENSI RENDAH)

#UMAP digunakan untuk:
#- Mereduksi ribuan gen menjadi 2 dimensi
#- Melihat pemisahan sampel secara global

#Transpose matriks ekspresi:
#UMAP bekerja pada OBSERVATION = sampel
umap_input <- t(ex)

#Jalankan UMAP
umap_result <- umap(umap_input)

#Simpan hasil ke data frame
umap_df <- data.frame(
  UMAP1 = umap_result$layout[, 1],
  UMAP2 = umap_result$layout[, 2],
  Group = gset$group
)

#Plot UMAP
ggplot(umap_df, aes(x = UMAP1, y = UMAP2, color = Group)) +
  geom_point(size = 3, alpha = 0.8) +
  theme_minimal() +
  labs(
    title = "UMAP Plot: Adjacent vs Tumor",
    x = "UMAP 1",
    y = "UMAP 2"
  )
```

```
#PART J.1 VISUALISASI VOLCANO PLOT

#Volcano plot menggabungkan:
#- Log fold change (efek biologis)
#- Signifikansi statistik

volcano_data <- data.frame(
  logFC = topTableResults$logFC,
  adj.P.Val = topTableResults$adj.P.Val,
  Gene = topTableResults$SYMBOL
)

#Klasifikasi status gen
volcano_data$status <- "NO"
volcano_data$status[volcano_data$logFC > 0.5 & volcano_data$adj.P.Val <
0.05] <- "UP"
volcano_data$status[volcano_data$logFC < -0.5 & volcano_data$adj.P.Val <
0.05] <- "DOWN"

#Visualisasi
ggplot(volcano_data, aes(x = logFC, y = -log10(adj.P.Val), color =
status)) +
  geom_point(alpha = 0.6) +
  scale_color_manual(values = c("DOWN" = "blue", "NO" = "grey", "UP" =
"red")) +
  geom_vline(xintercept = c(-0.5, 0.5), linetype = "dashed") +
  geom_hline(yintercept = -log10(0.05), linetype = "dashed") +
  theme_minimal() +
  ggtitle("Volcano Plot DEG")

#PART J.1.1 MENGHITUNG JUMLAH GEN PADA VOLCANO PLOT
n_up <- sum(topTableResults$logFC >= 0.5 & topTableResults$adj.P.Val <
0.05)

n_down <- sum(topTableResults$logFC <= -0.5 & topTableResults$adj.P.Val
< 0.05)

sum(n_up)

sum(n_down)
```

```
#PART J.2 VISUALISASI HEATMAP

#Heatmap digunakan untuk melihat pola ekspresi gen
#antar sampel berdasarkan gen-gen paling signifikan

#Pilih 50 gen paling signifikan berdasarkan adj.P.Val
topTableResults <- topTableResults[
  order(topTableResults$adj.P.Val),
]

top50 <- head(topTableResults, 50)

#Ambil matriks ekspresi untuk gen terpilih
mat_heatmap <- ex[top50$PROBEID, ]

#Gunakan Gene Symbol (fallback ke Probe ID)
gene_label <- ifelse(
  is.na(top50$SYMBOL) | top50$SYMBOL == "",
  top50$PROBEID,      # jika SYMBOL kosong → probe ID
  top50$SYMBOL        # jika ada → gene symbol
)

rownames(mat_heatmap) <- gene_label

#Pembersihan data (WAJIB agar tidak error hclust)
#Hapus baris dengan NA
mat_heatmap <- mat_heatmap[
  rowSums(is.na(mat_heatmap)) == 0,
]

#Hapus gen dengan varians nol
gene_variance <- apply(mat_heatmap, 1, var)
mat_heatmap <- mat_heatmap[gene_variance > 0, ]

#Anotasi kolom (kelompok sampel)
annotation_col <- data.frame(
  Group = gset$group
)

rownames(annotation_col) <- colnames(mat_heatmap)
```

```
#Visualisasi heatmap
pheatmap(
  mat_heatmap,
  scale = "row",                 # Z-score per gen
  annotation_col = annotation_col,
  show_colnames = FALSE,         # nama sampel dimatikan
  show_rownames = TRUE,
  fontsize_row = 7,
  clustering_distance_rows = "euclidean",
  clustering_distance_cols = "euclidean",
  clustering_method = "complete",
  main = "Top 50 Differentially Expressed Genes"
)

#PART K. ANALISIS GO & KEGG PATHWAY

#Mendapatkan list top 50 gen
cat(topTableResults$SYMBOL[1:50], sep = "\n")

#Analisis GO & KEGG Pathway dapat dilakukan melalui web tool seperti
Enrichr
#https://maayanlab.cloud/Enrichr/

#PART L. MENYIMPAN HASIL

# write.csv(): menyimpan hasil analisis ke file CSV
write.csv(topTableResults, "Hasil_GSE106582_DEG.csv")

message("Analisis selesai. File hasil telah disimpan.")
```

3. GO Enrichment & KEGG Pathway

Analisis GO *Enrichment*, meliputi *biological processes* (BPs), *molecular function* (MFs), dan *Celllular Components* (CCs) serta KEGG *Pathway* dilakukan melalui situs EnrichR (https://maayanlab.cloud/Enrichr/). Hasil analisis diurutkan berdasarkan nilai P value < 0.05.

C. Hasil dan Interpretasi

1. Identifikasi DEGs

Hasil analisis ekspresi gen pada dataset GSE106582 yang ditunjukkan Boxplot pada Gambar 1.1 menunjukkan bahwa distribusi nilai ekspresi seluruh sampel, baik kelompok jaringan normal maupun jaringan tumor, normal dan seragam serta mengindikasikan bahwa tidak terdapat pergeseran distribusi ekspresi antar sampel. Lebar box pada masing-masing sampel seragam dan menunjukkan bahwa tingkat variasi ekspresi gen antar sampel relatif homogen dan tidak terdapat sampel dengan variabilitas yang menyimpang. Secara keseluruhan, visualisasi boxplot menunjukkan data yang stabil dan tidak menunjukkan adanya *batch effect*, sehingga dataset layak untuk dilanjutkan ke analisis diferensial ekspresi gen.

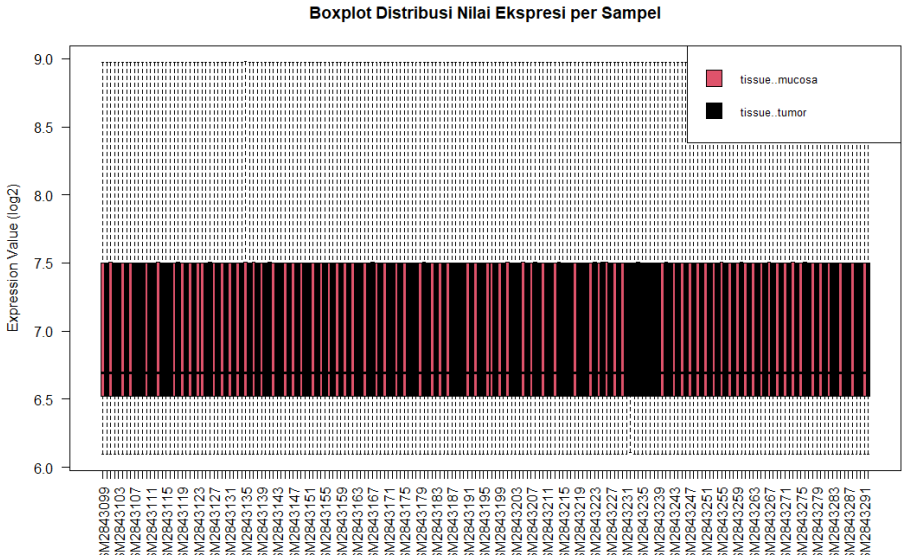

Gambar 1.1. Boxplot Distribusi Nilai Ekspresi per Sampel

Density plot yang ditunjukkan pada Gambar 1.2 menunjukkan bahwa distribusi nilai ekspresi gen pada kelompok jaringan normal dan jaringan tumor hampir sepenuhnya tumpang tindih. Bentuk kurva dengan adanya puncak pada log2 rendah menunjukkan adanya sebagian besar gen yang memiliki tingkat ekspresi sedang dan dengan adanya ekor panjang ke arah kanan menunjukkan adanya sejumlah kecil gen dengan ekspresi tinggi. Grafik tumpang tindih antar kedua kelompok menandakan tidak adanya pergeseran distribusi ekspresi gen antara jaringan normal dan tumor. Hal ini mengindikasikan bahwa perbedaan biologis kemungkinan terjadi pada subset gen tertentu dan bukan berupa perubahan seluruh transkriptom. Selain itu, kesamaan bentuk dan posisi kurva mengonfirmasi bahwa proses normalisasi dan transformasi telah menghasilkan distribusi yang konsisten antar kelompok dan menunjukkan tidak adanya *batch effect*.

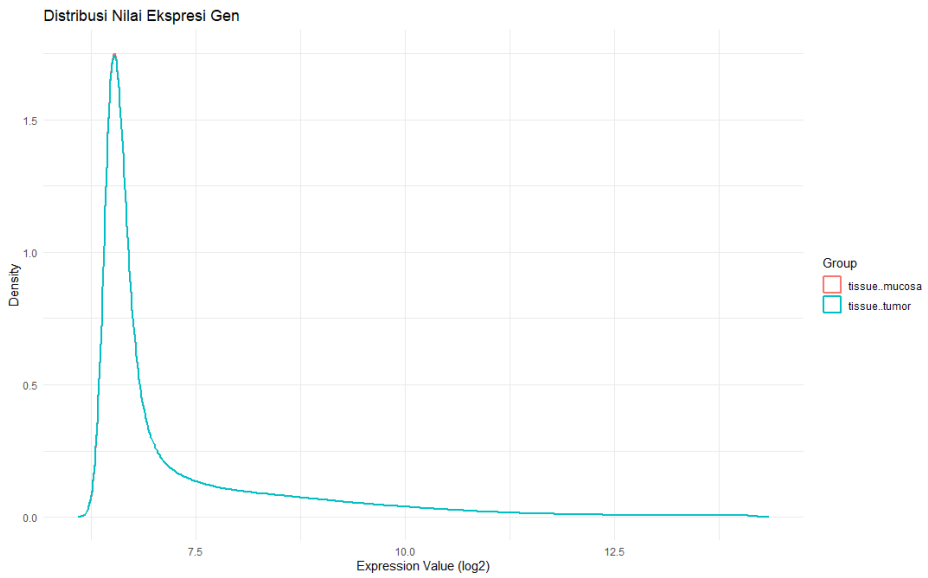

Gambar 1.2. Distribusi Nilai Ekspresi Gen

UMAP plot yang ditunjukkan pada gambar 1.3 menggambarkan pemisahan yang jelas antara kelompok jaringan normal dan jaringa tumor berdasarkan pola ekspresi gennya. Sampel tumor membentuk satu klaster di sisi kanan bawah, sedangkan sebagian besar sampel normal membentuk klaster terpisah di sisi kiri atas. Pemisahan ini mengindikasikan bahwa profil transkriptom antara jaringan normal dan tumor berbeda secara sistemik, bukan hanya pada sejumlah kecil gen. Adanya beberapa sampel yang berada di klaster yang tidak seharusnya mencerminakan kompleksitas dan heterogenitas dari jaringan tumor itu sendiri.

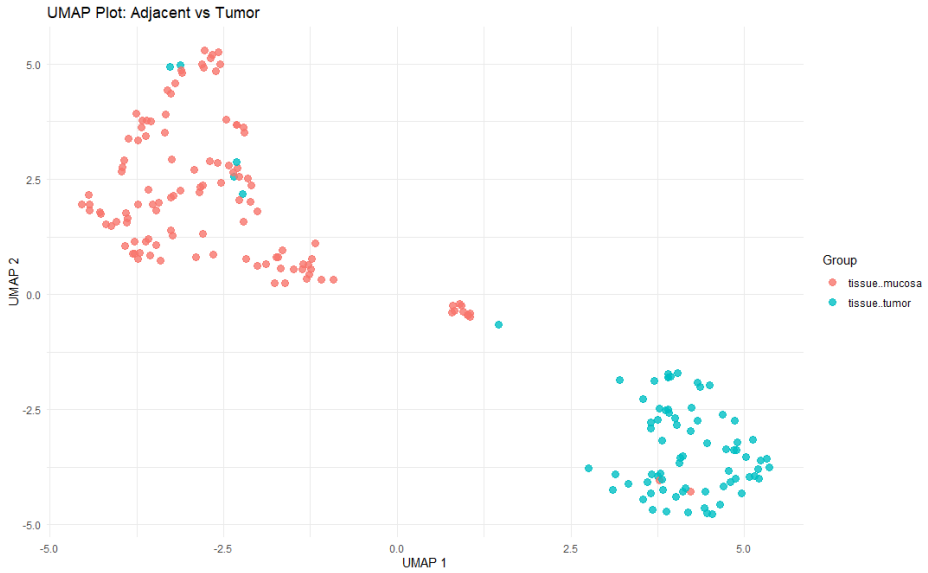

Gambar 1.3. UMAP Plot Ekspresi Gen

Volcano plot yang ditunjukkan pada Gambar 1.4 menunjukkan distribusi gen berdasarkan besar perubahan ekspresi logFC ≥ 0.5 (log2FC ≥ 1) untuk *upregulated genes* dan logFC ≤ -0.5 (log2FC ≤ -1) untuk *downregulated genes* serta tingkat signifikansi statistik −log10 adjusted p value 0.05. Dengan kriteria yang digunakan, teridentifikasi 1609 *upregulated genes* atau gen yang mengalami peningkatan ekspresi dan 1832 *downregulated genes* atau gen yang mengalami penurunan ekspresi. Hal ini mengindikasikan bahwa pada kondisi tumor terjadi kecenderungan penekanan ekspresi terhadap lebih banyak gen dibandingkan gen yang diinduksi ekspresinya.

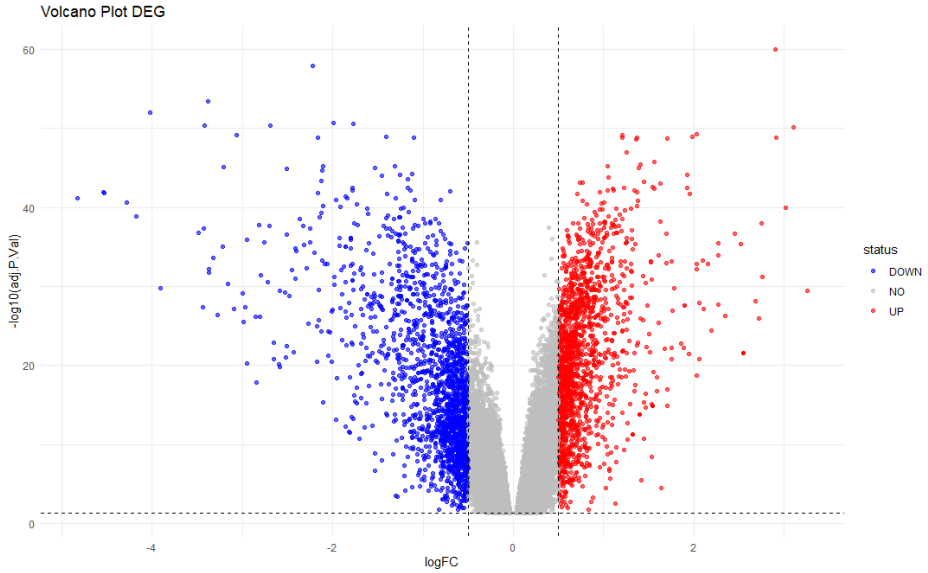

Gambar 1.4. Volcano Plot Ekspresi Gen

Heatmap yang ditunjukkan pada Gambar 1.5 menampilkan pola ekspresi 50 gen teratas dengan perbedaan paling signifikan antara kelompok jaringan normal dan jaringan tumor berdasarkan nilai Z *score* per gen. Warna merah menunjukkan ekspresi tinggi, sedangkan biru menunjukkan ekspresi rendah dibandingkan rata rata gen tersebut di seluruh sampel. Adanya pemisahan klaster yang jelas antar kelompok sampel menunjukkan bahwa 50 gen tersebut memiliki kemampuan diskriminatif yang kuat untuk membedakan kedua kondisi.

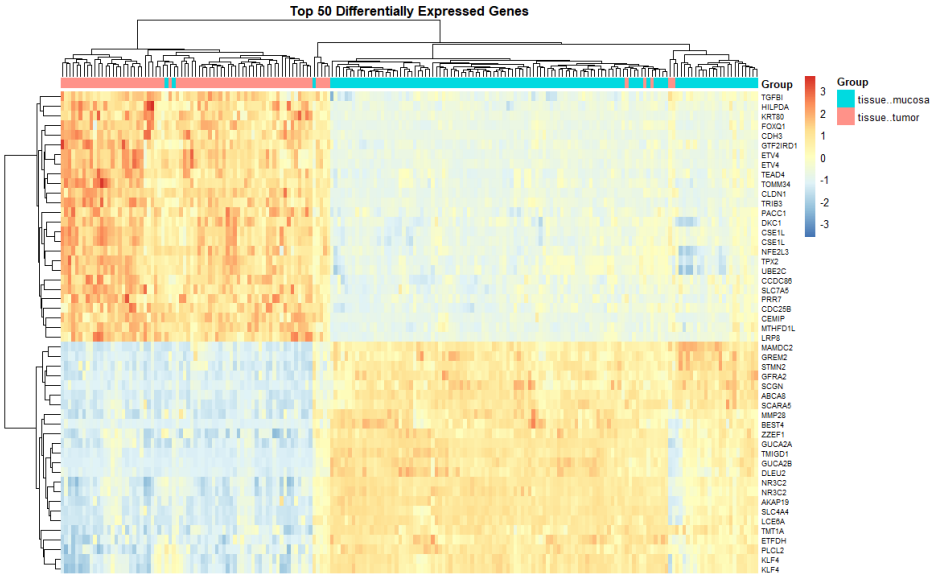

Gambar 1.5. Heatmap Top 50 DEGs

2. GO Enrichment & KEGG Pathway

Pada kategori *Biological Processes*, 50 gen tersebut berperan dalam Positive Regulation of Ubiquitin-Protein Transferase Activity, Xenobiotic Transport, Negative Regulation of Microtubule, dan proses biologis lainnya. Pada kategori *Cellular Components*, 50 gen terlibat dalam regulasi Basolateral Plasma Membrane, External Side of Apical Plasma Membrane, Lipid Droplet, dan komponen selular lainnya. Pada kategori *Molecular Functions*, 50 gen tersebut terlibat dalam Cyclase Activator Activity, Guanylate Cyclase Activator Activity, Ligand-Gated Monoatomic Anion Channel Activity, dan aktivitas fungsi molekuler lainnya. Sementara itu, berdasarkan analisis KEGG pathway, 50 gen tersebut hanya signifikan pada jalur *Proximal Tubule Bicarbonate Reclamation.*

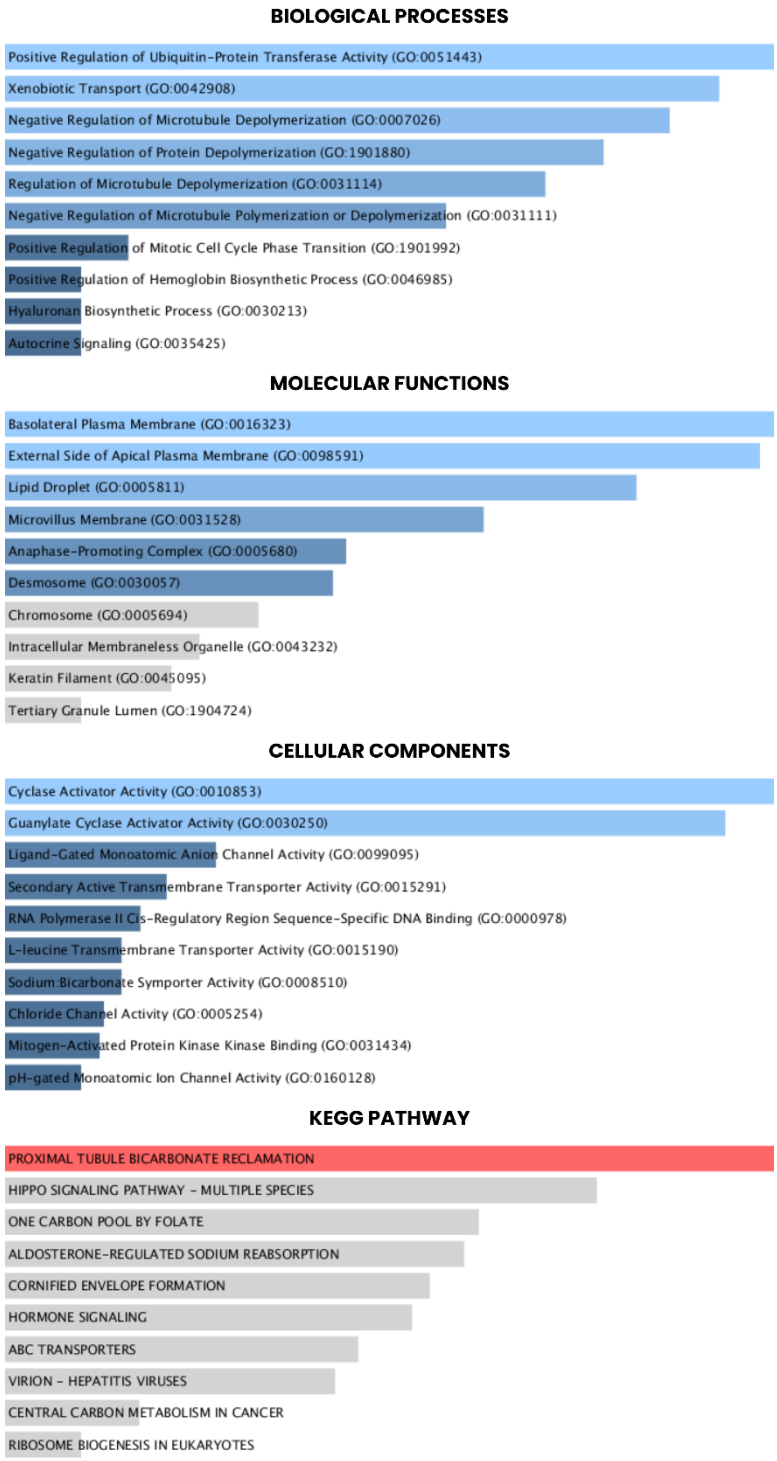

Gambar 2.1. Enrichment Top 50 DEGs

D. Kesimpulan

Berdasarkan analisis ekspresi gen yang telah dilakukan, terdapat perbedaan transkriptomik yang jelas antara kelompok jaringan normal dan jaringan tumor. Hal ini ditunjukkan oleh pemisahan klaster yang jelas pada UMAP, distribusi gen signifikan pada volcano plot dengan 1609 gen *upregulated* dan 1832 gen *downregulated* yang mengikuti

kriteria logFC ≥ 0.5 atau logFC ≤ -0.5 dan adjusted p value < 0.05, serta pola ekspresi yang kontras pada heatmap 50 gen paling signifikan yang mampu membedakan kedua kelompok secara konsisten. Temuan ini menunjukkan adanya disregulasi gen yang luas pada jaringan tumor yang kemungkinan berperan dalam proses proliferasi, perubahan diferensiasi sel, aktivasi jalur sinyal onkogenik, serta gangguan homeostasis jaringan, sehingga gen-gen yang teridentifikasi berpotensi menjadi kandidat biomarker diagnostik maupun target terapeutik, meskipun masih memerlukan validasi biologis dan analisis fungsional lanjutan untuk memastikan relevansi klinisnya.